

Paso 2 — Análisis de la fuente de datos · Ventas de vehículos

1. Perfil del archivo

Trabajamos con el archivo reducido de ventas de vehículos.

El archivo tiene ****290.990** filas y **16** columnas******.

Cada fila representa una operación de venta de un vehículo.

Columna	Significado	Tipo aparente	Valores / ejemplo
--- --- --- ---			
year	Año/modelo del vehículo	Entero	2012 a 2015
make	Marca	Texto	56 valores · 1.699 nulos
model	Modelo	Texto	430 valores · 1.797 nulos
trim	Versión del modelo	Texto	751 valores · 1.704 nulos
body	Tipo de carrocería	Texto	74 valores · 1.952 nulos
transmission	Tipo de transmisión	Texto	automatic / manual · 35.604 nulos
vin	Identificador del vehículo	ID	287.523 valores distintos · 4 nulos
state	Estado donde se realizó la venta	Texto	64 valores distintos
condition	Condición del vehículo	Numérico	mín. 1 · máx. 49 · 1.259 nulos
odometer	Millaje del vehículo	Numérico	mín. 1 · máx. 999.999 · 6 nulos
color	Color exterior	Texto	46 valores · 512 nulos
interior	Color interior	Texto	17 valores · 512 nulos
seller	Vendedor	Texto	6.813 valores distintos
mmr	Precio de referencia del mercado	Numérico	mín. 1.950 · máx. 178.000 · 38 nulos
sellingprice	Precio real de venta	Numérico	mín. 1 · máx. 230.000 · 12 nulos
saledate	Fecha de venta	Fecha	2.843 valores distintos · 12 nulos

Problemas encontrados

No se encontraron filas completamente duplicadas.

Sí encontramos algunos problemas en los datos:

- Hay ****26** filas mal formadas******, donde los valores aparecen corridos de columna.
- En `transmission` aparecen valores como `Sedan` y `sedan`, que en realidad no son transmisiones.
- En `state` aparecen algunos códigos VIN.
- En `color` aparecen algunos números que no representan colores.
- En `body` hay categorías escritas de distintas formas, por ejemplo `Sedan` y `sedan`.
- Hay ****3.463** VIN repetidos******.
- `transmission` tiene una cantidad importante de valores nulos.

Estos problemas se detectan ahora, pero la limpieza se hará más adelante en el Paso 4.

2. a) Indicadores conformados

Indicador	Columna / fórmula	Agregación
Cantidad de vehículos vendidos	Una fila = una venta	COUNT
Importe total de ventas	sellingprice	SUM
Precio promedio de venta	sellingprice	AVG
Kilometraje promedio	odometer	AVG

Aclaración

La cantidad de vehículos vendidos se obtiene contando las filas.

El importe total se obtiene sumando `sellingprice`.

El precio promedio se obtiene promediando `sellingprice`.

El kilometraje promedio se obtiene promediando `odometer`.

Más adelante, para los promedios se pueden guardar SUM y COUNT y calcular el promedio al consultar.

3. b) Correspondencias

Elemento del modelo	Tipo	Columna/s del archivo	Nota
Tiempo	Perspectiva	saledate	De acá se obtiene mes, trimestre y año
Vehículo	Perspectiva	make, model, body	Marca, modelo y carrocería
Ubicación	Perspectiva	state	Estado donde se realizó la venta
Vendedor	Perspectiva	seller	Vendedor del vehículo
Cantidad de vehículos vendidos	Indicador	filas del archivo	COUNT
Importe total de ventas	Indicador	sellingprice	SUM
Precio promedio de venta	Indicador	sellingprice	AVG
Kilometraje promedio	Indicador	odometer	AVG

Correspondencia con las preguntas

- **¿Cuántos vehículos se vendieron por marca y por mes?****
 - Indicador: cantidad de vehículos vendidos.
 - Columnas: `make` y `saledate`.
- **¿Cuál fue el precio promedio de venta por modelo y por año?****
 - Indicador: precio promedio.
 - Columnas: `model`, `sellingprice` y `saledate`.
- **¿Cuántos vehículos se vendieron por tipo de carrocería y por trimestre?****

- Indicador: cantidad de vehículos vendidos.
- Columnas: `body` y `saledate`.

4. ****¿Cuál fue el importe total de ventas por estado y por mes?****

- Indicador: importe total.
- Columnas: `state`, `sellingprice` y `saledate`.

5. ****¿Cuántos vehículos vendió cada vendedor por trimestre?****

- Indicador: cantidad de vehículos vendidos.
- Columnas: `seller` y `saledate`.

6. ****¿Cuál fue el kilometraje promedio por marca y por año?****

- Indicador: kilometraje promedio.
- Columnas: `odometer`, `make` y `saledate`.

Todos los indicadores y perspectivas tienen columnas reales en el archivo.

4. c) Granularidad

Cada fila representa una ****venta de un vehículo****.

Perspectivas

Perspectiva	Campos que entran	Se descarta	Por qué
--- --- --- ---			
Tiempo	mes, trimestre y año de saledate	hora exacta	Las preguntas no necesitan el horario
Vehículo	make, model, body	vin, trim, color, interior, transmission	No se necesitan para las preguntas actuales
Ubicación	state	—	Se analiza por estado
Vendedor	seller	—	Se analiza por vendedor

Tiempo

La columna que usamos para Tiempo es `saledate`.

De ella vamos a obtener:

- Mes
- Trimestre
- Año

El nivel más detallado que necesitamos es ****mes****, porque las preguntas no piden analizar por día.

Es importante aclarar que `year` no es el año de venta, sino el año/modelo del vehículo.

Consistencia de los valores

Columna	Qué se encontró	Cómo se piensa resolver
body	Hay valores como `Sedan` y `sedan`, `SUV` y `suv`	Unificar la escritura en el Paso 4
transmission	35.604 nulos y algunos valores incorrectos como `Sedan`	Revisar y normalizar en Paso 4
state	Algunas filas tienen un VIN en lugar de un estado	Revisar las filas mal formadas
color	Hay valores `—`, nulos y algunos números incorrectos	Unificar faltantes y corregir filas mal formadas
interior	Hay valores `` y nulos	Usar un valor como `Sin dato`
saledate	Hay nulos y algunas filas mal formadas	Validar las fechas en Paso 4
vin	Hay VIN repetidos	Revisar si representan ventas diferentes
odometer	Hay valores muy altos como 999.999	Revisarlos como posibles valores atípicos
sellingprice	Hay valores muy bajos como 1	Revisarlos antes de decidir si se eliminan

5. d) Modelo conceptual ampliado

